ТЕХНОЛОГИЯ ОДНОВРЕМЕННОЙ ЛОКАЛИЗАЦИИ И КАРТОГРАФИРОВАНИЯ VISUAL SLAM: МЕТОДЫ, АЛГОРИТМЫ И ПРОБЛЕМЫ

А.С. НЕСТЕРОВ (ООО “ЦПР РТСофт”)

Статья представляет собой обзор технологии Visual SLAM, которая позволяет устройствам одновременно строить карту окружающей среды и определять свое местоположение с использованием визуальных данных. В статье рассматриваются основные виды систем, работающих по технологии Visual SLAM, включая монокамерные, стерео- и RGB-D-системы. Статья также затрагивает перспективы развития этой технологии, включая интеграцию с методами глубокого машинного обучения и использование событийных камер. Материал статьи будет полезен исследователям и разработчикам, работающим в области робототехники, дополненной реальности и автономных систем.

Ключевые слова: *SLAM; VISUAL SLAM.*

ВВЕДЕНИЕ

Технология одновременной локализации и построения карты SLAM [1] (Simultaneous Localization and Mapping) широко применяется в различных областях, включая робототехнику, автономный транспорт, а также при реализации систем дополненной реальности. Основная задача технологии SLAM заключается в создании карты неизвестной среды и в одновременном определении местоположения системы сенсоров в этой среде на основе данных, получаемых с этих сенсоров. Для функционирования роботов построение карты играет ключевую роль, так как карта визуализирует ориентиры, что упрощает понимание окружающего пространства.

Кроме того, карта помогает оценить состояние робота, спланировать его движение и минимизировать ошибки при повторном посещении уже изученных участков. Структурная схема системы навигации представлена на рис. 1.

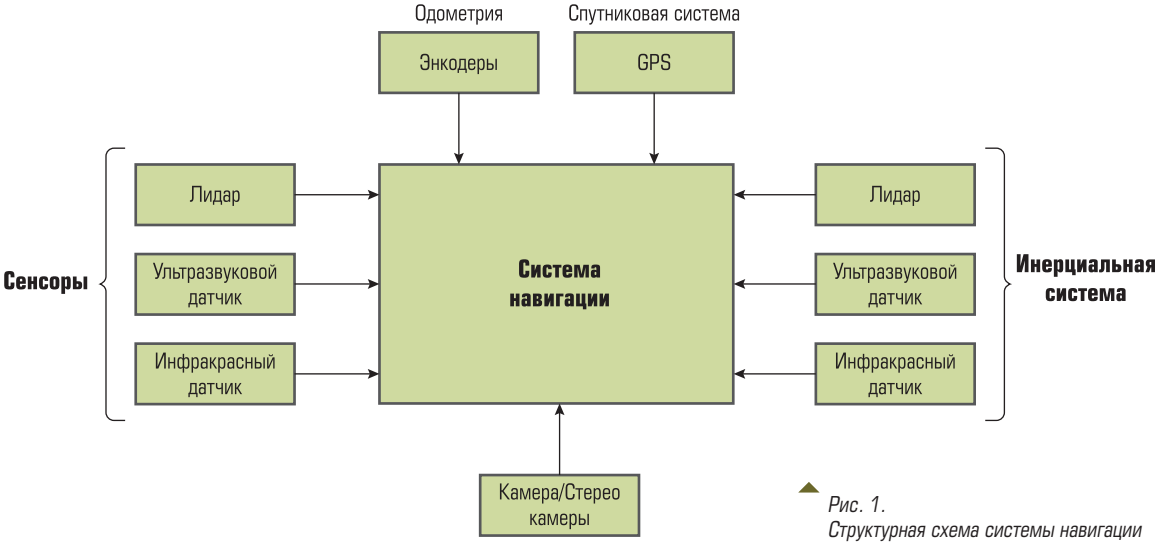

Рис. 1. Структурная схема системы навигации

1. ПРОЦЕСС СОЗДАНИЯ КАРТЫ

Создание карты неразрывно связано с двумя ключевыми задачами: локализацией и планированием маршрута. Эти задачи можно выразить тремя основными вопросами: каково строение окружающего мира, где находится робот и как ему достичь цели [2]. Первый вопрос решается через картографирование – построение модели среды, что требует определения положения ориентиров. Однако для этого необходимо знать местоположение самого робота, что является задачей локализации. Локализация позволяет определить координаты и ориентацию робота, фиксируя его позицию на карте. На основе картографирования и локализации решается третья задача – планирование маршрута, которое определяет оптимальную траекторию движения к цели с учетом текущего положения робота и особенностей окружающей среды.

2. ТЕХНОЛОГИЯ VISUAL SLAM

Подкласс технологии SLAM, который называется Visual SLAM [3], использует визуальные данные (изображения или видео) для решения вышеописанных задач локализации и построения карты. В отличие от классической технологии SLAM, которая может использовать различные типы сенсоров (табл. 1), технология Visual SLAM полагается исключительно на камеры. Подкласс Visual SLAM можно классифицировать по типу используемых сенсоров и подходов к обработке данных.

При использовании SLAM отображение карты осуществляется как в двухмерном, так и в трехмерном пространстве. Отображение местности в 3D является более сложным и, как правило, требует больше памяти. Однако это не всегда позволяет обеспечить качественное понимание окружающей среды, поэтому двухмерного отображения достаточно для большинства задач. Помимо этого, методы SLAM можно разделить по используемым подходам SLAM для представления карт:

- основанные на сетке точек (grid-based);
- на основе распознавания уникальных объектов (feature-based);
- на основе графиков (graph-based) для более разреженных изображений;
- топологические (topological) для распознавания типов местоположений;
- семантические (semantic) для более высокого уровня понимания окружающей среды.

Feature-based SLAM используют легко идентифицируемые элементы в среде и создают внутреннее представление о пространстве с учетом местоположения этих ориентиров. Исторически самый ранний и наиболее влиятельный SLAM-алгоритм основан на расширенном фильтре Калмана.

SLAM на основе графов или сетей также пытается создать карту с помощью графа, узлы которого соответствуют позициям робота в разные моменты времени, а ребра представляют собой пространственные ограничения, связывающие их вместе. Ограничения состоят в распределении вероятностей относительного преобразования между позициями. Используя граф, постро-

Таблица 1. Сравнение сенсоров

Сенсор	Описание	Преимущества	Недостатки
2D/3D сканирующие лидары. Диапазон измерения: 0,01-50 метров	Объект освещается коротким световым импульсом, и измеряется время, через которое сигнал вернется к источнику	• Быстрота сбора данных • Использование в любое время суток • Большое разрешение • Дальность измерений • Высокая точность	Высокая стоимость
Ультразвуковой датчик. Диапазон измерения: 0,03-6 метров	Ультразвуковые волны с частотой 65-400 кГц в виде кратковременного импульса излучаются в направлении контролируемой зоны 10-200 раз в секунду	• Относительно высокая скорость измерений • Небольшая стоимость • Эффективность работы в условиях густого тумана, задымленности	• Плохо воспринимает сигналы от звукопоглощающих объектов • Неточность измерения • Ограниченный диапазон измерений
Инфракрасный датчик. Диапазон измерения: 0,03-1,5 метров	Излучение с длиной волны 850±70 нм распространяется и отражается от объектов, находящихся в поле зрения сенсора. Возвращается на приемник. Испускаемый и отраженный луч образует треугольник “излучатель – объект отражения – приемник”	• Простота в использовании • Небольшая стоимость	• Ограниченный диапазон измерений • Не воспринимает прозрачную поверхность • Засветы от солнца • Некорректно определяет расстояния до светопоглощающих объектов

енный на основе измерений датчиков, система определяет наиболее вероятную конфигурацию позиций с учетом ребер графа. Одним из наиболее популярных подходов к SLAM на основе графов является метод отображения в реальном времени (VSLAM Rtabmap), основанный на инкрементном детекторе замыкания цикла на базе визуальных образов.

Теоретически наиболее простым методом является подход на основе сетки. При таком подходе среда разбивается на сетку точек определенного размера. Каждая точка может быть занята препятствием, не занята или не исследована. Например, ячейка со значением 1 будет считаться занятой, а другая, со значением 0, будет полностью свободной. Также значение точки может варьироваться от 0 до 1 при помощи промежуточных значений.

Топологическое представление проблемы SLAM направлено на создание графоподобного описания окружающей среды, а не точной метрической карты. В топологическом описании узлы могут соответствовать значимым местам, которые легко различить. Основополагающей идеей этого подхода стал принцип, согласно которому люди и животные не создают точных карт окружающей среды, в которой они находятся. Как правило, эти методы подходят для навигации в простых средах и применять их в более сложных и больших средах затруднительно.

Представление карт также может быть выполнено в виде семантических моделей. В отличие от топологического подхода, при котором отображение фильтрует метрическую информацию и использует только распознавание мест для определения местоположения, семантическое сопоставление связывает семантические концепции с объектами в окружающей среде. Семантическое отображение все еще находится на ранних стадиях разработки и в зависимости от уровня необходимых семантических возможностей оно может быть очень сложным для реализации.

Каждый тип имеет свои особенности, преимущества и ограничения, которые определяют его применимость в различных задачах. Рассмотрим основные типы Visual SLAM.

2.1. Монокамерная технология SLAM

Монокамерный SLAM [4] использует одну камеру для захвата изображений и восстановления трехмерной структуры пространства. Монокамеры являются наиболее простым и доступным типом сенсоров, применяемых в технологии Visual SLAM. Основная сложность здесь заключается в том, что камера предоставляет только двухмерные данные, а для построения трехмерной карты необходимо восстановить глубину. Это достигается с помощью методов эпиполярной геометрии. Например, при движении камеры ключевые точки (характерные особенности изображения) отслеживаются между кадрами и на основе их смещения вычисляется относительное положение камеры. Затем с помощью триангуляции восстанавливается трехмерная структура сцены – пространства, которое окружает камеру, включая объекты, поверхности и их расположение. Однако отсутствие прямого измерения глубины делает этот метод чувствительным к неточным данным, особенно при использовании слаботекстурированных поверхностей (однотонные стены, гладкий пол, монотонные объекты – поверхности, на которых отсутствуют четкие визуальные особенности, такие как контрастные границы, узор, углы) или при быстром движении камеры. Популярные алгоритмы, например, ORB-SLAM и PTAM (Parallel Tracking and Mapping), используют сложные оптимизационные методы, такие как пакетная корректировка (Bundle Adjustment), чтобы минимизировать ошибки и улучшить точность.

Одним из первых и наиболее известных алгоритмов является PTAM [5] (Parallel Tracking and Mapping). Алгоритм PTAM стал революционным, так как впервые разделил задачи отслеживания положения камеры и построения карты на две параллельные задачи. Это позволило значительно повысить производительность и точность системы. Алгоритм PTAM использует монокамеру, работает в реальном времени и популярен в приложениях дополненной реальности. Но и он имеет ограничения, такие как чувствительность к быстрым движениям камеры и сложность масштабирования для больших сцен.

Алгоритм ORB-SLAM [6] стал следующим шагом в эволюции технологии Visual SLAM. Он поддерживает моно-, стерео- и RGB-D-камеры и является универсальным инструментом для различных задач. Алгоритм ORB-SLAM использует метод ORB (Oriented FAST and Rotated BRIEF) для извлечения ключевых точек, что обеспечивает высокую скорость и устойчивость к изменениям освещения. Алгоритм включает три основных компонента: трекинг, построение карты и оптимизацию, а также поддерживает повторное использо-

вание карты и работу в больших масштабах благодаря применению графов ключевых кадров. При высокой эффективности есть и минус – алгоритм ORB-SLAM требует значительных вычислительных ресурсов, что может быть ограничением для использования маломощных устройств.

2.2. Stereo SLAM

Еще одна технология – Stereo SLAM, в отличие от монокамерной, использует две камеры, расположенные на фиксированном расстоянии друг от друга. Это позволяет напрямую вычислять глубину с помощью параллакса – смещения ключевых точек между изображениями, полученными с двух камер. Stereo SLAM более устойчив в слаботекстурированных сценах, так как наличие двух камер обеспечивает больше данных для сопоставления. Такой метод требует точной калибровки камер и синхронизации их работы. Кроме того, вычислительная сложность у этой технологии выше, чем у монокамерной SLAM из-за необходимости обработки двух изображений одновременно. Примером Stereo SLAM является Stereo LSD-SLAM (Large-Scale Direct SLAM), которая создает полуплотные карты, сочетая преимущества совместной работы стереокамер и эффективных алгоритмов оптимизации. Полуплотная карта представляет окружающее пространство, в котором восстановлены только ключевые точки и их трехмерные координаты, но отсутствует полная геометрия всех поверхностей (в отличие от плотных карт, где каждая точка пространства имеет свою глубину).

Алгоритм LSD-SLAM представляет собой подход, основанный на прямых методах, а не на характеристиках. Он работает с полуплотными картами, что позволяет ему восстанавливать не только ключевые точки, но и структуру сцены в целом. Алгоритм LSD-SLAM использует оптимизацию по яркости пикселей, а значит, устойчив к слаботекстурированным сценам. Однако ему требуется высокая вычислительная мощность, поэтому он может быть менее точным в условиях быстрого движения камеры.

Технология RGB-D SLAM [7] использует камеры с датчиками глубины, такие как Microsoft Kinect™ или Intel RealSense™ [8]. Камеры предоставляют не только цветное изображение, но и информацию о глубине для каждого пикселя. Это значительно упрощает задачу восстановления трехмерной структуры сцены, так как глубина измеряется напрямую. Технология RGB-D SLAM особенно эффективна в помещениях, где расстояние до объектов относительно небольшое. Алгоритмы, такие как KinectFusion, используют данные RGB-D для построения плотных 3D-моделей в реальном времени. Алгоритм использует ICP (Iterative Closest Point) для сопоставления облаков точек и интегрирует данные в глобальную модель с применением воксельной репрезентации (Voxel-based representation). Облако точек – основное представление 3D-сцены – набор трехмерных координат, соответствующих поверхности объектов в сцене, где каждая точка может также содержать цветовую информацию. Сопоставление облаков точек – процесс нахождения соответствия между точками в разных кадрах и вычисления преобразований. Kinect Fusion стал основой для многих последующих разработок в области SLAM с плотными моделями. Однако такие системы работают только на коротких расстояниях и могут быть чувствительны к внешним условиям, таким как яркий солнечный свет, который может нарушать работу инфракрасных датчиков.

Еще одним подходом является SVO (Semi-Direct Visual Odometry), который сочетает в себе преимущества feature-based- и direct-методов. SVO использует ключевые точки для инициализации и отслеживания, но также учитывает яркость пикселей для повышения точности отображения. Этот алгоритм отличается высокой скоростью работы и низкими требованиями к вычислительным ресурсам, что делает его подходящим для маломощных устройств, например, дронов. Однако SVO может быть менее устойчивым в сложных условиях, таких как слаботекстурированные сцены или быстрые движения камеры.

В области SLAM с плотными моделями также стоит отметить алгоритм ElasticFusion, который создает глобально согласованные плотные карты. ElasticFusion использует RGB-D-камеры и оптимизирует карту с учетом как геометрии, так и текстуры сцены. Этот алгоритм способен корректировать ошибки в реальном времени, что делает его подходящим для задач 3D-реконструкции. Однако ElasticFusion требует значительных вычислительных ресурсов и ограничен в масштабируемости.

Монокамерный SLAM подходит для простых и недорогих решений, Stereo SLAM обеспечивает более высокую точность, RGB-D SLAM подходит для задач 3D-реконструкции,

а Visual-Inertial SLAM сочетает в себе устойчивость и точность, необходимые для динамических сцен – окружения, в котором присутствуют движущиеся объекты, создающие помехи для классических SLAM-алгоритмов. Выбор конкретного подхода зависит от требований задачи, доступных ресурсов и условий эксплуатации.

Одним из наиболее распространенных альтернативных подходов является Lidar SLAM, который использует лазерные локаторы – лидары (Light Detection and Ranging) для измерения расстояния до объектов. Лидары излучают лазерные импульсы и измеряют время их возврата, что позволяет точно определять расстояние до объектов в сцене. Lidar SLAM часто используется в автономных автомобилях и промышленных роботах, где требуется высокая точность и устойчивость. По сравнению с Visual SLAM, Lidar SLAM имеет несколько ключевых преимуществ. Во-первых, лидары предоставляют точные данные о расстоянии, что упрощает задачу построения карты. Во-вторых, они менее чувствительны к изменениям освещения и текстуры сцены, что делает их более устойчивыми в сложных условиях. Однако лидары имеют и свои ограничения: они дороги, требуют значительных вычислительных ресурсов для обработки данных и имеют ограниченный обзор (обычно 360 градусов по горизонтали, но ограниченный по вертикали). В отличие от Visual SLAM, который может создавать плотные или полуплотные карты, Lidar SLAM обычно создает разреженные карты, основанные на облаках точек.

Еще одним альтернативным подходом является Radar SLAM, который использует радары для измерения расстояния и скорости объектов. Радары излучают радиоволны, анализируют их отражение и могут работать в условиях плохой видимости, таких как туман, дождь или снег. Radar SLAM часто используется в автономных транспортных средствах, где устойчивость к погодным условиям является критически важной. По сравнению с Visual SLAM, Radar SLAM имеет преимущества в условиях плохой видимости и может измерять скорость объектов, что полезно для задач навигации. Однако радары имеют более низкое разрешение по сравнению с лидарами и камерами, это ограничивает их способность к созданию детализированных карт. Кроме того, Radar SLAM требует сложных алгоритмов для обработки данных и может быть менее точным в условиях, где визуальные данные недостаточны.

Ультразвуковые сенсоры также используются в некоторых системах SLAM, особенно в робототехнике. Они измеряют расстояние до объектов с помощью звуковых волн и подходят для задач, где требуется низкая стоимость и простота использования. Однако ультразвуковые сенсоры имеют ограниченную дальность и низкое разрешение, что делает их менее подходящими для задач, требующих высокой точности. По сравнению с Visual SLAM, ультразвуковые системы SLAM обычно используются в простых приложениях, таких как навигация роботов-уборщиков или автоматические парковочные системы.

Visual-Inertial SLAM [9] представляет собой гибридный подход, который объединяет данные камеры и инерциального измерительного блока (IMU). Этот подход сочетает преимущества Visual SLAM (высокая детализация и плотные карты) с устойчивостью и точностью IMU, особенно в условиях быстрого движения или слаботекстурированных сцен. По сравнению с классическим Visual SLAM, Visual-Inertial SLAM более устойчив к ошибкам, вызванным быстрыми движениями камеры или временной потерей визуальных ориентиров. Однако интеграция данных IMU требует точной калибровки и синхронизации, а это довольно сложная задача.

На начальном этапе алгоритма система получает данные от IMU, которые включают линейное ускорение и угловую скорость. Эти данные интегрируются для оценки движения между двумя последовательными кадрами, что позволяет предсказать положение и ориентацию камеры на основе данных об ускорении и скорости. Процесс называется “предварительной интеграцией” и является важным шагом для корректной работы системы. Одновременно с этим изображения от монокамеры обрабатываются для извлечения визуальных признаков, таких как ключевые точки. Эти точки используются для отслеживания движения камеры между кадрами. Если трекинг признаков неудачен, например, из-за быстрого движения или слаботекстурированной сцены, система переходит к обработке данных IMU.

Далее система переходит к визуально-инерциальному выравниванию, где данные от камеры и IMU объединяются для более точной оценки положения и ориентации камеры. Этот процесс включает в себя сопоставление визуальных признаков между кадрами и использование данных IMU для коррекции ошибок, вызванных быстрым движением или временной потерей визуальных ориентиров.

VINS-Mono использует оптимизацию в скользящем окне, где учитываются только последние несколько кадров, что позволяет упростить вычисления и улучшить производительность. В рамках окна выполняется нелинейная оптимизация, которая минимизирует ошибки репроекции и инерциальных данных. Если текущий кадр считается ключевым, т.е. содержит много новых признаков или значительные изменения в сцене, он добавляется в базу данных ключевых кадров [12]. Ключевые кадры применяются для повторного использования карты и обнаружения петель.

Если система обнаруживает, что текущий кадр соответствует ранее посещенному месту, она выполняет оптимизацию графа положений (4-DoF Pose Graph Optimization). Это позволяет устранить накопленные ошибки и улучшить глобальную согласованность карты. В рамках оптимизации графа положений система минимизирует ошибки между ключевыми кадрами, используя ограничения, полученные из визуальных и инерциальных данных, что улучшает точность карты и траектории.

В результате работы VINS-Mono система выдает трехмерную карту среды, построенную на основе ключевых точек и данных IMU, а также оценивает положение и ориентацию камеры в реальном времени.

Однако одной из наиболее сложных проблем Visual SLAM является работа в динамических средах, где объекты движутся или изменяются со временем. В классических алгоритмах SLAM предполагается, что сцена статична, и все объекты в ней неподвижны. Однако в реальных условиях это предположение часто не выполняется. Например, в городской среде люди, автомобили и другие объекты постоянно движутся, что может нарушить работу алгоритма. Движущиеся объекты создают шум в данных, который может быть ошибочно интерпретирован как часть статичной сцены, что приводит к ошибкам в локализации и построении карты.

Проблема динамических сред особенно актуальна для задач, где точность и устойчивость критически важны, таких как автономные транспортные средства или роботы, работающие среди толпы (например, на складах, в торговых центрах или аэропортах). В таких условиях движущиеся объекты могут занимать значительную часть кадра, что делает задачу отделения статичных объектов от динамических крайне сложной. Например, если человек проходит перед камерой, алгоритм может ошибочно интерпретировать его движение как движение самой камеры, что приведет к ошибкам в оценке положения и ориентации.

Для решения проблемы динамических сред разрабатываются различные подходы. Одним из наиболее популярных является использование семантической сегментации сцены с помощью глубокого обучения. Нейронные сети могут быть обучены распознавать и классифицировать объекты в сцене, что позволяет отделить статичные объекты (например, стены или мебель) от динамических (например, людей или автомобилей). Это позволяет алгоритму игнорировать движущиеся объекты при построении карты и оценке движения камеры.

Другим подходом является использование временной информации для фильтрации динамических объектов. Например, если объект появляется в одном кадре и исчезает в следующем, он может быть классифицирован как динамический и исключен из обработки. Однако этот подход может быть менее эффективным в условиях, где объекты движутся медленно или остаются в кадре в течение длительного времени.

В заключение можно сказать, что технология Visual SLAM применима для задач, требующих высокой детализации и плотного построения карты, таких как дополненная реальность и 3D-реконструкция. Однако там, где требуется высокая точность, устойчивость к погодным условиям или работа в сложных средах, могут быть предпочтительны альтернативные подходы – Lidar SLAM, Radar SLAM или Visual-Inertial SLAM. Выбор конкретного подхода зависит от требований задачи, доступных сенсоров и вычислительных возможностей системы.

Список литературы

1. *Barros A.M., Michel M., Moline Y., Corre G., Carrel F.A.* Comprehensive Survey of Visual SLAM Algorithms [Электронный ресурс] // Robotics. – 2022. URL: *https://www.mdpi.com/2218-6581/11/1/24* – (This article belongs to the Topic Motion Planning and Control for Robotics).
2. *Stachniss C.* Robotic Mapping and Exploration; Springer: Berlin/Heidelberg, Germany, 2009; Volume 55.
3. *Gao X., Zhang T.* Introduction to Visual SLAM: From Theory to Practice / Transl. by T. Zhang, X. Gao. – Singapore: Springer Nature Singapore, 2021. – 376 p. – ISBN 978-981-16-4939-4.

4. *A ROS Implementation of the Mono-Slam Algorithm* [Электронный ресурс] // International Conference on Foundations of Computer Science & Technology. – January 2014. – URL: 10.5121/csit.2014.4131. – Лицензия: CC BY-NC 4.0.
5. *Using External Sensors in Solution of SLAM Task* [Электронный ресурс] // Journal of Physics: Conference Series. – 2018. – Т. 1015, № 3. – С. 032184. – URL: 10.1088/1742-6596/1015/3/032184 – Лицензия: CC BY 3.0.
6. *Панков В. Д.* Сравнение алгоритмов локализации ORB SLAM и LSD SLAM / В.Д. Панков, В. А. Шульга. – Текст: непосредственный // Молодой ученый. – 2018. – № 27 (213). – С. 16-19. – URL: *https://moluch.ru/archive/213/51977/*
7. *RGB-D SLAM Dataset and Benchmark* // Computer Vision Group: [сайт]. URL: *https://vision.in.tum.de/data/datasets/rgbd-dataset*
8. *Kinect™ and Intel RealSense™ D435 Comparison*: A Preliminary Study for Motion Analysis [Электронный ресурс] // 2019 IEEE International Conference on E-health Networking, Application & Services (HealthCom). – October 2019. – URL: *10.1109/HealthCom46333.2019.9009433*
9. *Visual and Inertial Odometry and SLAM* [Электронный ресурс] // Robotics and Perception Group, University of Zurich. URL: *https://rpg.ifi.uzh.ch/research_vo.html*
10. *Qin T., Li P., Shen S.* VINS-Mono: A Robust and Versatile Monocular Visual-Inertial State Estimator [Электронный ресурс] // arXiv. – 2017. – Режим доступа: *https://arxiv.org/pdf/1708.03852*
11. *Burak Kaan Özbek*. Metin Turan Research on the Availability of VINS-Mono and ORB-SLAM3 Algorithms for Aviation [Электронный ресурс] // WSEAS Transactions on Computers. – 2020. – Режим доступа: *https://wseas.com/journals/computers/2020/a545105-048.pdf*
12. *Mur-Artal R., Tardós J.D.* Fast Relocalisation and Loop Closing in Keyframe-Based SLAM // IEEE International Conference on Robotics and Automation (ICRA). – 2014.

Нестеров Александр Сергеевич *– программист ООО “ЦПР РТСофт”, аспирант МГТУ им. Н.Э. Баумана.*